

Relatório de Testes A/B de Cashback

Sumário executivo

Foram analisados 3 testes A/B de variação de % de cashback (Parceiros A, B e C), avaliando o impacto na margem líquida diária (comissão – cashback). A decisão de escalar uma variante segue dois filtros aplicados em sequência:

- Filtro estatístico: a diferença entre grupos é estatisticamente confiável? (IC95% não cruza zero e a diferença observada é maior que o effect size mínimo detectável, o MDE).
- Filtro de negócio: mesmo no cenário mais conservador da incerteza estatística, o ganho ainda compensa o esforço/risco de trocar a variante ativa? (limite inferior do IC95% comparado a um custo mínimo de troca, custo_troca).

Resultado consolidado

Parceiro	Decisão	Grupo recomendado
Parceiro A	inconclusivo: nenhum grupo supera todos os demais com confiança estatística suficiente	-
Parceiro B	escalar Grupo 1	Grupo 1
Parceiro C	escalar Grupo 1 (caso determinístico)	Grupo 1

Resultado também registrado e atualizado automaticamente em planilha de acompanhamento (Google Sheets): <https://docs.google.com/spreadsheets/d/1IWuPGGC3dJzRLDFo6DDItB7FoHLpuMkMyjO8ULBjX0E/edit> (acesso de leitura público).

Metodologia: como o custo_troca foi definido

O custo_troca representa o ganho mínimo de margem (R\$/dia) necessário para justificar o esforço e o risco de escalar uma variante para 100% do tráfego. Não é derivado estatisticamente dos dados: é uma estimativa de negócio, calculada aqui como o maior valor entre dois pisos:

- Custo operacional amortizado: tempo estimado de trabalho para reconfigurar a variante ativa, convertido em R\$/dia ao longo do período esperado de vigência da mudança. Estimativa ilustrativa: 6h de trabalho, a uma taxa de ~R\$15,15/hora (baseada em pesquisa de salário médio de estágio em Growth/IA no Brasil, ~R\$2.000/mês), amortizado em 30 dias, resultando em ~R\$3,03/dia.
- 1,5x o desvio-padrão diário (pooled, entre todos os grupos) da margem de cada parceiro: um piso de "ruído natural do negócio": ganhos menores que isso se perdem na variação que a operação já tem no dia a dia, mesmo sem nenhuma mudança.

Por que o maior dos dois, e não a soma ou a média?

A mudança precisa, simultaneamente, cobrir o custo de implementá-la E ser grande o suficiente para não se perder no ruído natural do negócio. Usar o máximo garante que os dois critérios sejam satisfeitos ao mesmo tempo.

Testamos a sensibilidade do custo operacional variando de 4h/15 dias a 6h/30 dias (R\$3 a R\$21/dia), em ambos os parceiros com incerteza estatística (A e B), o desvio-padrão domina o cálculo com folga, e o resultado final da decisão não muda. Isto é, a decisão de escalar ou não depende principalmente da variação natural do negócio, não da premissa (mais arbitrária) de custo operacional.

Como os dados não identificam explicitamente qual grupo era o controle (variante já existente antes do teste), usamos o desvio-padrão pooled entre todos os grupos de cada parceiro, evitando adicionar uma suposição não verificável sobre qual grupo era o baseline.

Sensibilidade do multiplicador (1,5×)

O multiplicador 1,5× (aplicado ao desvio-padrão pooled) também é uma escolha de calibração, não um valor derivado estatisticamente -- representa uma margem de segurança acima de 1 desvio-padrão puro, sem ser tão conservador quanto 2×. Testamos como a decisão se comporta variando esse multiplicador de 1× a 2×:

Parceiro	1×	1,5× (usado)	2×
A	inconclusivo	inconclusivo	inconclusivo
B	escalar Grupo 1	escalar Grupo 1	não compensa o risco
C	não se aplica (caso determinístico)	não se aplica	não se aplica

Parceiro A é robusto à escolha do multiplicador -- a decisão permanece "inconclusivo" em toda a faixa testada. Parceiro B tem um ponto de virada: em 2× o pooled (custo_troca = R\$ 2.563,76/dia), a diferença deixa de compensar o risco de troca, revertendo a recomendação de "escalar" para "manter controle". Isso mostra que a decisão do Parceiro B, embora sólida em 1,5×, tem uma margem de segurança menor que a do Parceiro A -- informação relevante para quem for validar o custo_troca definitivo com o time de growth.

Parceiro A

Período analisado: 01/01/2011 a 02/04/2011

Grupos testados: Grupo 1, Grupo 2, Grupo 3

Resultado estatístico

Grupo	Margem média (R\$/dia)
Grupo 1	4.399,03
Grupo 2	3.886,08
Grupo 3	2.872,68

Teste F conjunto: $p = 0,0014$ (diferença significativa entre grupos).

Effect size mínimo detectável (MDE): R\$ 1.169,76/dia: diferenças menores que isso não têm poder estatístico suficiente para serem confiáveis, dado o tamanho da amostra.

Filtro de negócio

custo_troca aplicado: R\$ 3.041,68/dia (ver metodologia). A decisão só recomenda escalar uma variante se o limite inferior do IC95% da diferença superar esse valor.

Decisão final

DECISÃO: INCONCLUSIVO

Apesar do teste F conjunto indicar diferença significativa entre os grupos, nenhum grupo supera todos os demais simultaneamente com confiança estatística. Apenas o Grupo 1 bate o Grupo 3 com confiança: a diferença entre Grupo 1 e Grupo 2 não é estatisticamente significativa, e a diferença entre Grupo 2 e Grupo 3, embora significativa, fica abaixo do MDE daquele par (efeito pequeno demais para confiar, dado o tamanho da amostra). Recomenda-se re-teste com maior N ou investigação adicional antes de escalar qualquer variante.

Parceiro B

Período analisado: 01/05/2011 a 30/06/2011

Grupos testados: Grupo 1, Grupo 2, Grupo 3

Resultado estatístico

Grupo	Margem média (R\$/dia)
Grupo 1	4.697,87
Grupo 2	2.346,84
Grupo 3	862,18

Teste F conjunto: $p = 0,0000$ (diferença significativa entre grupos).

Effect size mínimo detectável (MDE): R\$ 461,17/dia: diferenças menores que isso não têm poder estatístico suficiente para serem confiáveis, dado o tamanho da amostra.

Filtro de negócio

custo_troca aplicado: R\$ 1.922,82/dia (ver metodologia). A decisão só recomenda escalar uma variante se o limite inferior do IC95% da diferença superar esse valor.

Decisão final

DECISÃO: ESCALAR

Grupo 1 supera todos os demais grupos com diferença estatisticamente confiável (IC95% + MDE) e economicamente relevante (limite inferior do IC95% acima do custo de troca de R\$ 1.922,82/dia). Recomenda-se escalar Grupo 1 para 100% do tráfego.

Parceiro C

Período analisado: 01/07/2011 a 14/08/2011

Grupos testados: Grupo 1, Grupo 2

Resultado estatístico

Grupo	Margem média (R\$/dia)
Grupo 1	772,64
Grupo 2	0,00

Caso determinístico: pelo menos um grupo apresenta variância zero, dispensando teste estatístico.

Filtro de negócio

custo_troca não se aplica neste caso (diferença determinística, sem incerteza a considerar).

Decisão final

DECISÃO: ESCALAR

Diferença determinística: o Grupo 2 apresenta margem zero em 100% dos dias (cashback distribuído é idêntico à comissão recebida em todas as observações), enquanto o Grupo 1 mantém margem média de R\$ 772,64/dia. Não há incerteza a testar: a diferença é certa, não estimada.

⚠ Nota de atenção: o cashback do Grupo 2 é idêntico à comissão em 100% das linhas, zerando a margem, vale confirmar se isso é uma regra de negócio intencional (repassse total) ou um erro de exportação de dados antes de tratar essa decisão como definitiva.

Conclusão

Pergunta que motivou essa análise: “Dado esse teste A/B, qual variante de cashback devemos escalar pra 100% do tráfego?”

A resposta varia por parceiro. Dos três testes analisados, apenas o Parceiro B produziu uma decisão estatisticamente sólida e economicamente justificada: escalar o Grupo 1. O Parceiro C aponta na mesma direção, mas por um motivo estrutural diferente (diferença determinística, não estatística), que ainda depende de confirmação sobre a origem do dado antes de ser tratado como definitivo. O Parceiro A, por sua vez, não permite recomendação nenhuma no momento: não porque os grupos sejam iguais, mas porque a amostra atual não tem poder estatístico para dizer se são diferentes.

Esse padrão é o resultado esperado de uma metodologia que prioriza não recomendar uma mudança sem confiança suficiente, mesmo que isso signifique deixar uma decisão em aberto. Fica, portanto, em aberto o que fazer com o Parceiro A: re-testar com mais amostra, ou aceitar que, pelo menos por ora, nenhuma variante testada justifica sair do status quo.

Limitações

- O custo_troca usado é uma estimativa ilustrativa; em um cenário real de produção, precisaria ser validado com dados de negócio (custo operacional real, apetite de risco).

- Parceiro C: a origem do dado do Grupo 2 (margem zero) não pode ser confirmada com os dados disponíveis; pode ser regra de negócio (repassse total) ou erro de exportação.
- Parceiros A e B têm datas com choque comum (outlier simultâneo em múltiplos grupos), tratadas via dummy na regressão.

Referências metodológicas

WOOLDRIDGE, Jeffrey M. *Introductory econometrics: a modern approach*. 5. ed. Mason: South-Western Cengage Learning, 2012. (base para teste F conjunto, inferência em regressão múltipla e forma funcional do modelo).

NEWBY, Whitney K.; WEST, Kenneth D. A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*, v. 55, n. 3, p. 703-708, 1987. (base para os erros-padrão HAC usados na regressão, robustos a heterocedasticidade e autocorrelação serial em dado em série temporal diária).

RIBEIRO, Rafael S. M. Introdução à Econometria: notas de aula. Centro de Desenvolvimento e Planejamento Regional (CEDEPLAR), Faculdade de Ciências Econômicas (FACE), Universidade Federal de Minas Gerais (UFMG), 2026.